

Predlog projekta iz predmeta Računarski vid

Uporedna analiza reprezentacija slike primenjenih na klasifikaciju saobraćajnih znakova pri kontrolisanim degradacijama ulaza

Student: Mihajlo Madić, broj indeksa 2119

Niš, 2026.

1. Naziv i kratak opis projekta

Naziv projekta: *Uporedna analiza reprezentacija slike primenjenih na klasifikaciju saobraćajnih znakova pri kontrolisanim degradacijama ulaza.*

Cilj projekta je sistematsko poređenje četiri različite reprezentacije [1] slike saobraćajnog znaka, od kojih su tri dobijene "klasičnim" metodama, a jedna je naučena – metodama dubokog učenja. Date reprezentacije se koriste za izradu rešenja klasifikacije saobraćajnih znakova, nad GTSRB [2] (*German Traffic Sign Recognition Benchmark*) skupom podataka, koji će biti korišćen za razvoj i evaluaciju rešenja. Ulaz sistema je isečak slike (eng. *crop*), dimenzija između 15×15 i 250×250 piksela, koji sadrži tačno jedan saobraćajni znak, a izlaz je jedna od 43 klase znakova.

Suština projekta nije u postizanju najviše moguće tačnosti klasifikacije, GTSRB je zasićen skup podataka na kome savremene konvolucione mreže prelaze 99% [3], već u **analizi pod kojim uslovima je koja reprezentacija primenljiva**. Četiri posmatrane reprezentacije se razlikuju po više strukturnih osobina istovremeno (globalna nasuprot lokalnoj, sa očuvanim nasuprot odbačenim prostornim rasporedom, ručno projektovana tj. "klasična" nasuprot naučenoj), pa se očekuje da redosled uspešnosti metoda zavisi od vrste degradacije ulazne slike. Upravo ta *interakcija* između reprezentacije i tipa degradacije predstavlja glavni rezultat projekta¹.

Ovakva postavka problema je relevantna zato što daje informaciju pri odabiru date reprezentacije u implementaciji realnog sistema. U realnim okolnostima, odabir određene reprezentacije mora biti donešen u skladu sa nedostacima sistema u okviru koga se dati klasifikator koristi, a u toj odluci je najrelevantnija otpornost klasifikatora na onu vrstu degradacije koja u datoj primeni dominira, npr. zamućenje usled kretanja, šum pri slabom osvetljenju ili nepreciznost izlaza detektora.

2. Projektni tim

Ime i prezime	Broj indeksa
Mihajlo Madić	2119

¹Kroz ceo dokument su **zelenom bojom** podvučeni elementi koji čine minimalni skup rezultata – ono što autor smatra da mora biti realizovano da bi se projekat smatrao uspešnim. **Narandžastom bojom** podvučen je *prošireni skup ciljeva*, koji se realizuju samo ako vreme i resursi dozvole.

3. Kategorija projekta

Projekat pripada **tehnološkoj kategoriji**, sa *eksperimentalno-analitičkim* karakterom.

Tehnološki deo je u implementaciji i praktičnom poređenju metoda obrađenih na časovima – PCA (metod sopstvenih vektora, isti princip kao Eigenfaces [4]), HOG deskriptora [5], metoda vreća vizuelnih reči nad SIFT deskriptorima [6, 7], i konvolucione neuronske mreže – ali u okviru jedinstvenog, kontrolisanog eksperimentalnog protokola. Za razliku od primera sa časova, gde se svaka od ovih metoda demonstrira izolovano i na sopstvenom skupu podataka, ovde se sve metode primenjuju na isti skup, uz isti preprocesing, isti klasifikator i istu metodologiju evaluacije, čime se razlike u rezultatima mogu pripisati isključivo samoj reprezentaciji.

Analitički deo je u tome što se ne izveštavaju samo skalarne vrednosti tačnosti, već i ponašanje metoda pod kontrolisanim degradacijama ulaza, uz unapred zapisana očekivanja i njihovu naknadnu proveru.

4. Detaljniji opis projekta i očekivani rezultati

4.1 Kontekst – mesto projekta u širem sistemu

Kompletan sistem za prepoznavanje i razumevanje saobraćajne signalizacije iz video snimka, snimljenog kamerom uperenom u smeru kretanja vozila, u literaturi se standardno razlaže na fazu detekcije i fazu klasifikacije [8, 9]. Radi preciznijeg razgraničenja opsega ovog projekta, ta podela je ovde dodatno raščlanjena na pet modula:

Modul	Uloga	Status u ovom projektu
M1	Detekcija / lokalizacija – pronalaženje kandidatnih regiona koji sadrže znak u punom kadru	<i>Van opsega</i>
M2	Praćenje – propagacija detektovanog regiona kroz naredne kadrove pomoću optičkog toka, radi uštede računskih resursa	<i>Van opsega</i>
M3	Prepoznavanje (klasifikacija) – dodeljivanje klase izdvojenom isečku	<u>Predmet ovog projekta</u>
M4	Vremenska agregacija – objedinjavanje odluka po jednom fizičkom znaku kroz više kadrova	<i>Van opsega</i>
M5	Semantičko tumačenje – prevođenje prepoznatih znakova u ograničenja i preporuke za vozilo	<i>Van opsega</i>

Ovaj projekat realizuje isključivo modul M3, i to nad isečcima čije su granice date anotacijom skupa podataka, a ne izlazom detektora. Moduli M1, M2, M4 i M5 se u ovom dokumentu opisuju samo radi kontekstualizacije – oni nisu deo predmeta rada, ne implementiraju se, i ne evaluiraju se. Ovo ograničenje opsega je namerno i proizilazi iz opsega samog predmeta i vremenskih resursa; obrazloženje i pravac daljeg razvoja dati su u Dodatku A.

Jedan element projekta je ipak svesno oblikovan tako da služi budućem povezivanju sa modulom M1: merenje osetljivosti klasifikatora na pomeraj i promenu razmere graničnog okvira, nad GTSDB skupom, koji sadrži kadrove punih scena [9] (opisano detaljnije u odeljku 6.2). Realan detektor nikada ne daje isečke tako precizno centrirane i uokvirene kao ručna anotacija, pa ovo merenje kvantifikuje koliko bi tačnosti bilo izgubljeno kada bi se modul M3 spojio sa modulom M1.

4.2 Formulacija problema

- **Ulaz:** slika $I \in \mathbb{R}^{h \times w \times 3}$, isečak koji sadrži tačno jedan saobraćajni znak; $h, w \in [15, 250]$.
- **Izlaz:** oznaka klase $\hat{y} \in \{1, \dots, 43\}$.
- **Zadatak:** naučiti preslikavanje $I \mapsto \hat{y}$ i uporediti kvalitet tog preslikavanja za različite izbore funkcije reprezentacije $\phi(I) \mapsto \mathbf{x} \in \mathbb{R}^d$.

4.3 Posmatrane reprezentacije

Reprezentacije se razlikuju po strukturnim osobinama koje su navedene u tabeli, i upravo se od tih razlika očekuje različito ponašanje pod različitim degradacijama:

Reprezentacija	Prostorni raspored	Domet	Učena?
PCA	holistički, osetljiv na poravnanje	globalni	ne
HOG	kruta mreža, raspored očuvan	lokalni	ne
BoVW	bez rasporeda , raspored odbačen	lokalni	samo rečnik
CNN	hijerarhijski, invarijantan kroz <i>pooling</i>	lokalni	u potpunosti

Ključna metodološka odluka: klasifikator se drži *fiksni* (linearni SVM) za sve četiri reprezentacije, kako bi razlike u rezultatima bile pripisive reprezentaciji, a ne klasifikatoru. Zbog toga se konvoluciona mreža evaluira u dve varijante: (a) kao ekstraktor obeležja, gde se izlaz prethodnog sloja prosleđuje istom linearnom SVM klasifikatoru, čime postaje direktno uporediva sa ostale tri metode; i (b) end-to-end, sa sopstvenim softmax slojem. Ukupno se, dakle, poredi **pet konfiguracija**.

4.4 Očekivani rezultati

- implementirane sve četiri reprezentacije i pet konfiguracija klasifikacije, nad jedinstvenim protokolom evaluacije;
- podela na skupove za trening i validaciju izvršena po sekvencama (eng. track), a ne po pojedinačnim slikama – videti odeljak 6.1;
- tabela glavnog poređenja: tačnost, makro-F1 mera, vreme treniranja, vreme inferencije po slici, veličina modela i dimenzija vektora obeležja;
- krive robusnosti – tačnost kao funkcija jačine degradacije, za četiri tipa degradacije;
- analiza tačnosti u funkciji veličine znaka – test skup podeljen u opsege po visini graničnog okvira;
- matrice konfuzije za najbolju i najlošiju metodu, uz tabelu najčešće mešanih parova klasa;
- tabela poređenja unapred zapisanih očekivanja sa dobijenim rezultatima, sa obrazloženjem odstupanja;
- ablaciona analiza preprocesiranja – uticaj ekvalizacije histograma i izbora prostora boja;
- pretraga hiperparametara za svaku od metoda, umesto podrazumevanih vrednosti;
- tehnički izveštaj sa analizom arhitekture rešenja i diskusijom rezultata.

5. Tehnologije koje će biti korišćene

- **Python** kao glavni programski jezik.
- **OpenCV** [10] za SIFT deskriptore, konverziju prostora boja, CLAHE ekvalizaciju i filtriranje.
- **scikit-image** [11] za HOG deskriptor – pogodniji od `cv2.HOGDescriptor` za male kvadratne isečke, čije su podrazumevane vrednosti podešene za detekciju pešaka u prozoru 64×128 .
- **scikit-learn** [12] za PCA, `MiniBatchKMeans` (izgradnja vizuelnog rečnika), `LinearSVC` i metrike.
- **PyTorch** [13] za konvolucionu mrežu.
- **NumPy, Pandas i Matplotlib** za obradu rezultata i generisanje grafika.

Napomena o računskim resursima. Razvojna mašina (AMD Ryzen 7 5800H, 8 jezgara / 16 niti, 13 GB usable RAM) nema upotrebljiv GPU – integrisana Vega grafika nije podržana od strane ROCm platforme, a CUDA nije primenljiva. Ceo projekat se stoga izvršava isključivo na procesoru. Ovo ograničenje diktira dve konkretne odluke: koristi se `LinearSVC` umesto SVM-a sa kernel funkcijom, čija je složenost $O(n^2)$ – $O(n^3)$ i koja bi nad 39 000 uzoraka trajala satima; i koristi se `MiniBatchKMeans` umesto klasičnog k -means algoritma pri izgradnji vizuelnog rečnika. Mala konvoluciona mreža (ispod milion parametara, ulaz 48×48) se na 16 niti trenira u prihvatljivom vremenu.

6. Validacija i podaci za testiranje

6.1 Skup podataka i podela

Koristi se **GTSRB** (*German Traffic Sign Recognition Benchmark*) [2] – 43 klase, 39 209 slika za trening i 12 630 za testiranje, sa anotacijom koja za svaku sliku sadrži dimenzije, koordinate graničnog okvira znaka unutar isečka, i oznaku klase.

Skup ima osobinu koja se u praksi često previdi, tj. trening slike su grupisane u **sekvence od po 30 kadrova istog fizičkog znaka**, snimljenih dok mu se vozilo približava. Nasumična podela na trening i validaciju bi zato razdvojila skoro identične kadrove istog znaka na obe strane, što veštački podiže validacionu tačnost. Podela se stoga vrši po identifikatoru sekvence, a ne po pojedinačnoj slici, uz automatsku proveru da nijedna sekvenca ne pripada obema stranama podele.

Klase u GTSRB skupu su izrazito nebalansirane (odnos najzastupljenije i najređe klase je oko 10 : 1), zbog čega se pored tačnosti obavezno izveštava i makro-F1 mera, koja svakoj klasi daje jednak značaj.

6.2 Kontrolisane degradacije

Test skup se evaluira pod **tri** tipa kontrolisane degradacije, svaki na pet nivoa jačine:

1. **Aditivni Gausov šum** – $\sigma \in \{0, 5, 10, 20, 40\}$; simulira šum senzora pri slabom osvetljenju.
2. **Zamućenje usled kretanja** – dužina jezgra $\in \{0, 3, 5, 9, 15\}$ piksela, nasumičan ugao; simulira kretanje vozila.
3. **Promena osvetljenosti** – gama korekcija, $\gamma \in \{0.4, 0.7, 1.0, 1.5, 2.5\}$; simulira ekstremne uslove ekspozicije.

Prvobitno je planirana i četvrta degradacija, perturbacija graničnog okvira, ali je analiza samog skupa podataka pokazala da ona nad GTSRB skupom **nije izvodljiva na pošten način**. GTSRB slike su već isečene oko znaka, sa medijanom margine od svega 16,7% veličine okvira; sve izvan te margine odbačeno je pri formiranju skupa i ne postoji ni u jednoj datoteci. Jedini način da se takav pomeraj ipak proizvede jeste veštačko dopunjavanje ivica, čime bi se merio i postupak dopunjavanja, pored izabrane reprezentacije.

Ovakva vrsta degradacije se stoga izmešta na skupove podataka koji sadrže **kadrove punih scena**, a u ovom radu će se vršiti evaluacija robusnosti opisanih modela nad GTSDb skupom pri nivoima pomeraja $\{0, 10, 20, 30, 40\}\%$ po razmeri i položaju. GTSDb sadrži 1 213 anotiranih znakova u 741 kadru dimenzija 1360×800 , sa istom šemom od 43 klase, pa se pomeraj realizuje isecanjem iz stvarne scene, bez ijednog veštački generisanog piksela. Nulti nivo pomeraja reprodukuje kadriranje GTSRB skupa (okvir uvećan za oko 17%), kako bi razlika u odnosu na njega merila isključivo grešku okvira, a ne promenu kadriranja; razlika između čistog GTSRB rezultata i GTSDb rezultata pri nultom pomeraju zasebno se izveštava kao mera *generalizacije između skupova podataka*. Zbog male i neravnomerne zastupljenosti klasa u GTSDb skupu (14 od 43 klase ima manje od 10 primeraka) na tom skupu se izveštava isključivo tačnost, ne i makro-F1.

Pomeraj okvira **ne ulazi u trening**, već se modeli treniraju isključivo nad GTSRB skupom, sa kadriranjem kakvo skup pruža. Time se meri *inherentna* otpornost reprezentacije na grešku okvira, što je informativnije upravo zato što model takvu perturbaciju nikada nije video, a eksperimentalna kontrola ostaje neizmenjena. Ovo merenje je, kao što je objašnjeno u odeljku 4.1, direktna priprema za potencijalno buduće povezivanje sa modulom M1.

6.3 Metrike

- **Tačnost i makro-F1 mera** na test skupu;
- **F1 mera po klasi i matrica konfuzije**;
- **tačnost po opsezima veličine znaka** – opsezi $[0, 32)$, $[32, 48)$, $[48, 72)$, $[72, \infty)$ piksela visine okvira; manji znak odgovara većoj udaljenosti u realnom scenariju;
- **krive robusnosti** – tačnost u funkciji nivoa svake od tri degradacije, prikazana relativno u odnosu na tačnost datog metoda na čistom skupu, kako bi se poredila *brzina opadanja* a ne polazna vrednost;
- **cena (*computational price*)** – vreme treniranja, vreme inferencije po slici (medijana iz najmanje tri merenja, uz odbacivanje prvog poziva), veličina modela u megabajtima i dimenzija vektora obeležja.

6.4 Kriterijum uspešnosti

Projekat se smatra uspešnim ako su sve četiri reprezentacije implementirane i evaluirane nad jedinstvenim protokolom, ako je podela po sekvencama sprovedena i proverena, i ako su dobijene krive robusnosti koje omogućavaju smislenu diskusiju o tome koja metoda otkazuje pod kojim uslovima. **Uspešnost se ne meri postignutom apsolutnom tačnošću**, jer je GTSRB zasićen skup na kome je visoka tačnost očekivana i sama po sebi ne predstavlja rezultat.

Pre pokretanja eksperimenata biće zapisana konkretna očekivanja o tome koja će reprezentacija biti najrobusnija pod kojom degradacijom, sa obrazloženjem izvedenim iz strukturnih osobina iz tabele u odeljku 4.3. Naknadno poređenje očekivanja sa rezultatima – uključujući i objašnjenje onih očekivanja koja se nisu ostvarila – predstavlja jezgro diskusije u izveštaju.

7. Literatura, linkovi i postojeća rešenja

- [1] Y. Bengio, A. Courville, and P. Vincent. Representation learning: A review and new perspectives. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 35(8):1798–1828, 2013.
- [2] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel. Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition. *Neural Networks*, 32:323–332, 2012. https://benchmark.ini.rub.de/gtsrb_dataset.html.
- [3] D. Cireřan, U. Meier, J. Masci, and J. Schmidhuber. Multi-column deep neural network for traffic sign classification. In *Neural Networks*, volume 32, pages 333–338, 2012.
- [4] M. Turk and A. Pentland. Face recognition using eigenfaces. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 586–591, 1991.
- [5] N. Dalal and B. Triggs. Histograms of oriented gradients for human detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893, 2005.
- [6] D. G. Lowe. Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60(2):91–110, 2004.
- [7] G. Csurka, C. Dance, L. Fan, J. Willamowski, and C. Bray. Visual categorization with bags of keypoints. In *ECCV Workshop on Statistical Learning in Computer Vision*, pages 1–22, 2004.
- [8] A. Møgelmoose, M. M. Trivedi, and T. B. Moeslund. Vision-based traffic sign detection and analysis for intelligent driver assistance systems: Perspectives and survey. *IEEE Transactions on Intelligent Transportation Systems*, 13(4):1484–1497, 2012.
- [9] S. Houben, J. Stallkamp, J. Salmen, M. Schlipsing, and C. Igel. Detection of traffic signs in real-world images: The German Traffic Sign Detection Benchmark. In *International Joint Conference on Neural Networks (IJCNN)*, 2013. https://benchmark.ini.rub.de/gtsdb_news.html.
- [10] G. Bradski. The OpenCV library. *Dr. Dobb's Journal of Software Tools*, 2000. <https://opencv.org/>.
- [11] S. van der Walt, J. L. Schönberger, J. Nunez-Iglesias, F. Boulogne, J. D. Warner, N. Yager, E. Gouillart, and T. Yu. scikit-image: Image processing in Python. *PeerJ*, 2:e453, 2014. <https://scikit-image.org/>.
- [12] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011. <https://scikit-learn.org/>.
- [13] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, et al. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019. <https://pytorch.org/>.
- [14] R. Szeliski. *Computer Vision: Algorithms and Applications*. Springer, 2010. Pogl. 3 (obrada slike, str. 87–180), pogl. 4 (detekcija i uparivanje karakterističnih tačaka, str. 181–234), pogl. 14 (prepoznavanje, str. 575–640).
- [15] A. Milosavljević. *Računarski vid*. Edicija: Osnovni udžbenici. Elektronski fakultet, Univerzitet u Nišu, 2021.
- [16] R. Laganiere. *OpenCV 3 Computer Vision Application Programming Cookbook*. Packt Publishing, 3 edition, 2017. Pogl. 3 (boje), pogl. 6 (filtriranje), pogl. 8–9 (karakteristične tačke i deskriptori), pogl. 14 (učenje iz primera).

- [17] B. D. Lucas and T. Kanade. An iterative image registration technique with an application to stereo vision. In *International Joint Conference on Artificial Intelligence (IJCAI)*, pages 674–679, 1981.
- [18] C. Plizzari, G. Goletto, A. Furnari, S. Bansal, F. Ragusa, G. M. Farinella, D. Damen, and T. Tommasi. An outlook into the future of egocentric vision. *International Journal of Computer Vision*, 132:4880–4936, 2024. <https://doi.org/10.1007/s11263-024-02095-7>.

Dodatak A – Razlozi odabira teme

Tema je izabrana iz tri razloga.

1. Prepoznavanje saobraćajnih znakova je zadatak koji prirodno objedinjuje veliki broj oblasti obrađenih na predmetu – prostore boja i filtriranje kroz pretprocesiranje, detekciju karakterističnih tačaka i SIFT deskriptor kroz metod vreća vizuelnih reči, generativni pristup prepoznavanju kroz PCA (isti princip kao Eigenfaces metod), diskriminacioni pristup kroz HOG deskriptor, i konvolucione mreže kroz duboko učenje. Umesto da se svaka od ovih tema demonstrira izolovano, one se ovde stavljaju u direktno poređenje.
2. Opseg projekta je namerno i eksplicitno ograničen na jedan modul šireg sistema. Autor smatra da je pošteno i korisnije realizovati jedan modul do kraja, sa urednom metodologijom i proverljivim rezultatima, nego površno dodirnuti ceo lanac obrade. Moduli koji su ostavljeni van opsega – detekcija u punom kadru, praćenje kroz optički tok, vremenska agregacija odluka – opisani su u odeljku 4.1 upravo zato da bi granica bila nedvosmislena.
3. Projekat je zamišljen kao osnova za dalji rad. Klasifikator razvijen ovde postaje komponenta kompletnog sistema za prepoznavanje saobraćajne signalizacije iz video snimka, čiji bi naredni koraci bili: detekcija kandidatnih regiona nad GTSDb skupom, propagacija detekcija kroz kadrove pomoću optičkog toka [17] radi postizanja rada u realnom vremenu, i procena udaljenosti znaka na osnovu modela kamere i poznatih fizičkih dimenzija znaka. Merenje osetljivosti na pomeraj graničnog okvira, uvedeno u ovom projektu, direktno je motivisano tim nastavkom – ono unapred kvantifikuje gubitak tačnosti pri prelasku sa anotiranih na detektovane isečke. Šire posmatrano, isti metodološki problem – prepoznavanje objekata iz neprekidnog toka kadrova snimljenih pokretnom kamerom iz prvog lica, uz stroga ograničenja kašnjenja i računskih resursa – predstavlja jedno od otvorenih pitanja egocentričnog računarskog vida, oblasti koja poslednjih godina beleži izražen rast razvojem nosivih uređaja sa kamerom; novija sveobuhvatna pregledna studija te oblasti izdvaja rad u realnom vremenu i pri minimalnom kašnjenju kao zahtev koji postojeće metode još uvek ne ispunjavaju [18].

Dodatak B – Tabela akronima

Akronim	Značenje
GTSRB	German Traffic Sign Recognition Benchmark
GTSDb	German Traffic Sign Detection Benchmark
PCA	Principal Component Analysis (analiza glavnih komponenti)
HOG	Histogram of Oriented Gradients (histogram orijentisanih gradijenata)
SIFT	Scale-Invariant Feature Transform
BoVW	Bag of Visual Words (vreća vizuelnih reči)
CNN	Convolutional Neural Network (konvoluciona neuronska mreža)
SVM	Support Vector Machine (metod potpornih vektora)
CLAHE	Contrast Limited Adaptive Histogram Equalization
ROI	Region of Interest (region od interesa)
RAM	Random Access Memory
GPU	Graphics Processing Unit