

Projekat iz predmeta Računarski vid

Uporedna analiza reprezentacija slike primenjenih na klasifikaciju saobraćajnih znakova pri kontrolisanim degradacijama ulaza

Student: Mihajlo Madić, broj indeksa 2119

Niš, 2026.

Sažetak

Pri izboru reprezentacije slike za klasifikaciju saobraćajnih znakova uobičajeno je da odluku donese tačnost na čistim podacima. Ovaj rad ispituje da li je to dovoljno. Upoređene su četiri reprezentacije — PCA [1], HOG [2], metod vreća vizuelnih reči nad gustim SIFT deskriptorima [3, 4] i konvoluciona neuronska mreža u dve varijante — nad GTSRB skupom podataka [5], uz namerno strogu kontrolu. Klasifikator, pretprocesiranje i protokol evaluacije drže se fiksnim, tako da razlike u rezultatima ostaju pripisive isključivo reprezentaciji.

Umesto jednog broja po metodi, svaka konfiguracija je izmerena i na čistom test skupu i pod tri kontrolisane degradacije — šumom, zamućenjem usled kretanja i gama korekcijom — svaka na pet nivoa jačine.

Glavni nalaz je da tačnost na čistim podacima **ne predviđa otpornost**. Pod jakim šumom redosled uspešnosti se preokreće, metoda koja je na čistom ulazu poslednja postaje najotpornija i nadmašuje konvolucionu mrežu na istim pikselima, dok metoda koja se oslanja na gradijente gubi gotovo sve. Pod zamućenjem i gama korekcijom tog preokreta nema, pa je interakcija između reprezentacije i degradacije stvarna, ali vezana za *vrstu* degradacije, a ne opšta.

Većina unapred zapisanih očekivanja se obistinila. Dva promašaja su zadržana i analizirana, jer su informativnija od onih koja su se potvrdila — oba upućuju na isto: presudno nije da li metoda računa gradijente, već da li reprezentacija interno normalizuje i kog je tipa ta normalizacija. Praktična posledica je da se reprezentacija bira prema degradaciji koja u datoj primeni dominira, a ne prema rang-listi na čistim podacima.

Ključne reči: računarski vid, klasifikacija saobraćajnih znakova, GTSRB, reprezentacije slike, PCA, HOG, vreća vizuelnih reči, konvolucione neuronske mreže, robusnost.

1. Uvod i postavka problema

Cilj projekta je sistematsko poređenje četiri reprezentacije [6] slike saobraćajnog znaka, od kojih su tri dobijene „klasičnim” metodima, a jedna je naučena. Ulaz sistema je isečak slike dimenzija između 15×15 i 250×250 piksela, koji sadrži tačno jedan saobraćajni znak, a izlaz je jedna od 43 klase.

Suština projekta nije u postizanju najviše moguće tačnosti, jer je GTSRB zasićen skup na kome savremene konvolucione mreže prelaze 99% [7]. Suština je u **analizi pod kojim uslovima je koja reprezentacija primenljiva**. Posmatrane reprezentacije se razlikuju po više strukturnih osobina istovremeno, pa se očekivalo da redosled uspešnosti zavisi od vrste degradacije ulazne slike. Upravo ta *interakcija* između reprezentacije i tipa degradacije predstavlja glavni rezultat.

Postavka je relevantna zato što daje informaciju pri odabiru reprezentacije u realnom sistemu. U realnim okolnostima odabir mora biti donesen u skladu sa nedostacima sistema u okviru koga se klasifikator koristi, a u toj odluci je najrelevantnija otpornost na onu vrstu degradacije koja u datoj primeni dominira – zamućenje usled kretanja, šum pri slabom osvetljenju ili nepreciznost izlaza detektora.

1.1 Mesto projekta u širem sistemu

Kompletnan sistem za prepoznavanje saobraćajne signalizacije iz video snimka standardno se razlaže na fazu detekcije i fazu klasifikacije [8, 9]. Ovaj projekat isporučuje **isključivo modul klasifikacije** — ulaz je već isečen isečak, izlaz je klasa. Detekcija na punim kadrovima, praćenje, kalibracija kamere i procena rastojanja su eksplicitno van opsega.

Ta granica ima jednu merljivu posledicu koja je i sama rezultat, i o njoj je reč u odeljku 8.3: perturbacija graničnog okvira – degradacija koja bi najdirektnije povezala ovaj modul sa detektorom – **nije izvodljiva nad GTSRB skupom na pošten način**, i to je izmereno, a ne pretpostavljeno.

1.2 Posmatrane reprezentacije

Reprezentacije se razlikuju po strukturnim osobinama navedenim u tabeli, i upravo se od tih razlika očekivalo različito ponašanje pod različitim degradacijama.

Reprezentacija	Prostorni raspored	Domet	Učena?
PCA	holistička, kritična na poravnanje	globalni	ne
HOG	kruta mreža, raspored očuvan	lokalni	ne
BoVW	bez rasporeda , raspored odbačen	lokalni	samo rečnik
CNN	hijerarhijska, invarijantna na <i>pooling</i>	lokalni	potpuno

Ključna metodološka odluka: klasifikator se drži *fiksni*m (linearni SVM) za sve četiri reprezentacije, kako bi razlike bile pripisive reprezentaciji, a ne klasifikatoru. Zbog toga se konvoluciona mreža evaluira u dve varijante: (a) kao ekstraktor obeležja, gde se izlaz pretposlednjeg sloja prosleđuje istom linearnom SVM klasifikatoru, čime postaje direktno uporediva sa ostale tri metode; i (b) *end-to-end*, sa sopstvenim softmax slojem. Ukupno se poredi **pet konfiguracija**.

2. Korišćene tehnologije

Ceo projekat je u Python-u 3.11, sa zavisnostima zaključanim preko **Poetry**-ja, u tri grupe (**main**, **research**, **dev**) kako bi okruženje bilo obnovljivo iz čistog kloniranja repozitorijuma.

Biblioteka	Uloga u projektu
OpenCV	SIFT deskriptori (patent istekao, sada u osnovnom paketu), CLAHE, konverzije prostora boja, filtriranje, kernel zamućenja
scikit-image	HOG deskriptor – konfigurabilniji od <code>cv2.HOGDescriptor</code> , čiji su podrazumevani parametri podešeni za prozore 64×128 za detekciju pešaka i nezgodni su za male kvadratne isečke
scikit-learn	PCA (<code>svd_solver='randomized'</code>), <code>MiniBatchKMeans</code> za vizuelni rečnik, <code>LinearSVC</code> kao zajednički klasifikator, metrike
PyTorch (CPU)	konvoluciona mreža; instaliran iz eksplicitnog CPU indeksa
NumPy, Pandas, Matplotlib	obrađivanje rezultata i generisanje svih slika
pytest, ruff	351 test i statička analiza; pokreću se pre svakog upisa u repozitorijum
PlantUML	dijagrami arhitekture i pipeline-a, generisani iz izvora, ne crtani ručno

2.1 Ograničenje računskih resursa i dve odluke koje je nametnulo

Razvojna mašina (AMD Ryzen 7 5800H, 8 jezgara / 16 niti, 13 GB radne memorije) **nema upotrebljiv GPU** – integrisana Vega grafika nije podržana od strane ROCm platforme, a CUDA nije primenljiva. Ceo projekat se izvršava isključivo na procesoru, i to nije samo neugodnost. diktiralo je dve konkretne odluke koje su vidljive u rezultatima.

- **LinearSVC umesto SVM-a sa kernel funkcijom.** Složenost kernel SVM-a je $O(n^2)$ – $O(n^3)$ i nad 39.000 uzoraka trajala bi satima. Ovo je ujedno i srećna okolnost za postavku, jer je linearan klasifikator *slabiji*, pa razlike između metoda ostaju razlike između reprezentacija, a ne rezultat toga koliko je klasifikator uspeo da nadoknadi.
- **MiniBatchKMeans umesto klasičnog k -means algoritma** pri izgradnji vizuelnog rečnika. Oko 200.000 deskriptora od po 128 dimenzija stalo bi u memoriju, ali pune Lloyd-ove iteracije nad njima su nepotrebno spore, a rečnik je sredstvo za kodiranje, a ne predmet proučavanja.

Broj niti se **zaključava u vreme izvršavanja** preko `threadpoolctl`, a ne samo promenljivama okruženja. Razlog je merljiv. BLAS biblioteke čitaju `OMP_NUM_THREADS` u trenutku sopstvenog uvoza, a alat za sortiranje uvoza postavlja `import numpy` iznad `from gtsrb import config` – pa bi zaključavanje bilo tiho neaktivno upravo u skriptama u kojima je bitno.

3. Arhitektura softvera

Kod je podeljen na **biblioteku gtsrb** (gde je sva logika, pokrivena testovima) i **skripte** (koje samo pozivaju biblioteku i upisuju artefakte). Nijedna skripta ne sadrži logiku koja bi mogla da se razlikuje između dve skripte – to je jedini način da tvrdnja o jedinstvenom protokolu bude proverljiva.




Figure 1: Tri sloja — skripte pozivaju biblioteku, biblioteka upisuje artefakte. Strelice su agregirane radi čitljivosti – svaka skripta koristi više modula.

3.1 Moduli biblioteke

Modul	Odgovornost
config	jedno seme, putanje, konstante skupa, zaključavanje broja niti, i <code>rng_for()</code> – seed izveden iz sadržaja , ne iz redosleda izvršavanja
data	učitavanje anotacija, izvedeni <code>roi_w/roi_h</code> , i podela po sekvencama; validira broj redova, opseg klasa, ROI unutar granica i pravilo „jedna klasa po sekvenci”
preprocessing	tri imenovane konfiguracije, resize sa interpolacijom biranom <i>po slici</i>
cache	uint8 <code>.npy</code> keš sa otiskom pipeline-a; 83× brže od ponovnog čitanja PPM datoteka, uz <code>--verify</code> režim koji poredi bit za bit sa referentnom implementacijom
degradations	registar tri degradacije; svaka deklariše <i>sopstveni</i> nivo identiteta
representations/	<code>pca, hog, boww, cnn</code> – sve iza istog protokola
tuning	izbor <i>C</i> nad validacijom po makro-F1; pravilo izbora živi na jednom mestu
training	petlja treniranja mreže, rano zaustavljanje, vraćanje težina najbolje epohe
evaluation	tačnost, makro-F1, F1 po klasi, matrica konfuzije, najčešći parovi zamene, tačnost po grupama – sve sa <code>labels=range(43)</code>
timing	medijana od najmanje tri merenja uz odbacivanje prvog poziva, plus <code>platform_info()</code>
results	upis i čitanje <code>results.csv</code> , provera kompletnosti mreže, <code>latest_per_cell()</code>

3.2 Zajednički interfejs – ono što „jedinstven protokol” čini proverljivim

Sve četiri reprezentacije implementiraju isti Protocol:

<code>fit(images)</code>	→ <code>self</code> (uči iz <i>čistih trening</i> slika)
<code>transform(images)</code>	→ <code>(n, n_features)</code> float32
<code>n_features</code>	dimenzija izlaza – kolona u Tabeli 1
<code>name</code>	identifikator u koloni <code>method</code> datoteke <code>results.csv</code>

Neke reprezentacije ne uče ništa (HOG), neke uče bez nadzora (PCA, BoVW rečnik), a jedna uči sa nadzorom (mreža) – interfejs ih ne razlikuje, jer mreža evaluacije mora da iterira preko svih pet konfiguracija bez ijednog izuzetka. **Da protokol nije zajednički, tvrdnja iz odeljka 1.2 da su razlike pripisive reprezentaciji bila bi stvar konvencije, a ne konstrukcije.**

Dva pravila važe za svaku implementaciju i ugrađena su u interfejs, a ne ostavljena disciplini: **prilagođavanje isključivo nad trening podskupom** (lako je pogrešiti kod PCA i BoVW rečnika, koji ne koriste oznake, pa se prilagođavanje nad svime *čini* bezopasnim), i **prilagođavanje isključivo nad čistim slikama** (degradacije su stresor u vreme testiranja; ponovno prilagođavanje po uslovu merilo bi koliko se metoda može *pretrenirati* za stresor, što je drugo pitanje).

3.3 Rezultati kao jedna tabela

Svi rezultati se dopisuju u `results.csv`, u *tidy* obliku:

```
run_id, method, preproc, degradation, level, metric, value
```

`run_id` je `<vreme>-<commit>` i povezuje se sa `results/platform_<run_id>.json`, koji beleži procesor, memoriju, *ostvaren* broj niti, opterećenje sistema i verzije biblioteka. Datoteka je **samo za dopisivanje** — ponovno pokretanje dodaje redove umesto da ih prepíše, pa svaki potrošač mora da odluči na koji run misli – što radi `latest_per_cell()`.

To nije akademska sitnica. Kada je PCA model ponovo prilagođen zbog izmene protokola, jedna skripta za tabelu je filtrirala po *prefiksi* `run_id`-a i nastavila da štampa prevaziđene brojeve dok su svi ostali dokumenti bili ispravljeni. Pravilo je zato premešteno u biblioteku, da ga svaki potrošač deli.

3.4 Testovi – šta je zapravo osigurano

351 test pokriva biblioteku. Nekoliko njih nije rutinsko, jer pinuju svojstva bez kojih bi rezultati bili tiho pogrešni:

- **nijedna sekvenca ne sme biti na obe strane podele** – plus provera premisa na kojima to počiva (jedna klasa po sekvenci, kompozitni ključ);
- **HOG ne uči ništa** – prilagođavanje nad dve disjunktne polovine mora dati bit-identične deskriptore;
- **veličina bloka pri kodiranju ne sme menjati rezultat** – `chunk=7` i `chunk=1000` daju bit-identične histograme;
- **`embed()` je deterministična i u train režimu**, i vraća režim koji je zatekla;
- **reprezentacija se učitava sa *sopstvenim* pretprocesiranjem** – ime konfiguracije se čita iz artefakta, nikada iz zastavice.

3.5 Najznačajniji detalji implementacije

Pet odluka koje nisu očigledne, a menjaju rezultate:

Raspored u memoriji menja rezultate u float32. `PCA.fit` ostavlja `components_` u Fortran rasporedu, a povratak kroz `joblib` ga vraća u C rasporedu. Vrednosti su bit-identične, ali BLAS bira drugo jezgro za množenje, pa se projekcije razlikuju za oko 10^{-6} – *model se ponašao drugačije nakon ponovnog učitavanja*. Rešeno normalizacijom rasporeda u trenutku prilagođavanja.

Interpolacija pri skaliranju bira se po slici. 39,2% isečaka se smanjuje, a 60,8% uvećava; fiksni izbor ubacuje artefakt od oko četiri nivoa sivog, koreliran sa veličinom znaka.

Seed degradacija izveden je iz sadržaja. Jedno semenovanje na početku učinilo bi degradiran test skup zavisnim od redosleda izvršavanja, pa bi metode bile poređene nad *različitim* pikselima. Mreža evaluacije uz to iterira redosledom (pretprocesiranje → uslov → metoda), pa svakoj metodi predaje *isti objekat niza* – čime je to strukturno nemoguće, a ne samo sprečeno semenovanjem.

Veličina bloka pri kodiranju računa se u bajtovima, ne u slikama. Blok deskriptora je $\text{chunk} \times \text{n_keypoints} \times 128 \times 4$ bajta, pa isti broj slika košta 0,12 GB pri 64 ključne tačke i 1,10 GB pri 576. Formula mora da obuhvati i dodelu najbližem centru, koja raste sa veličinom rečnika.

Vraća se najbolja epoha, ne poslednja. *patience* epoha bez poboljšanja su po konstrukciji epohe u kojima model nije postao bolji i možda jeste postao lošiji. Na prijavljenom treniranju, vraćanje poslednje epohe koštalo bi **0,63 pp** makro-F1.

4. Eksperimentalni protokol

4.1 Skup podataka i podela na skupove

GTSRB sadrži 39.209 slika za treniranje i 12.630 za testiranje, u 43 klase. Skup je **neuravnotežen** $10,7\times$ (210 slika za klasu 0 naspram 2.250 za klasu 2 u skupu za treniranje; $12,5\times$ u test skupu), zbog čega se kao glavna metrika izveštava **makro-F1**, a ne tačnost, koja je dominirana velikim klasama, dok makro-F1 sve klase tretira jednako.

Podela na trening i validaciju mora biti po sekvencama, nikako po slikama. Slike u GTSRB skupu grupisane su u sekvence od po 30 kadrova istog fizičkog znaka. Nasumična podela po slikama razdvaja skoro identične kadrove na obe strane i naduvava validacionu tačnost.

Ova tvrdnja je **izmerena, a ne samo navedena**. Isti model je treniran dvaput – jednom sa podelom po sekvencama, jednom sa nasumičnom podelom po slikama (prosek tri *seed*-a):

	podela po sekvencama	nasumična po slikama
validaciona tačnost	0,8442	0,8950 (+5,08 pp)
validacioni makro-F1	0,7977	0,8936 (+9,58 pp)

Uzrok je izmeren nad istim podelama — 1.305–1.306 od 1.307 sekvenci završi na obe strane, a **100% validacionih slika zadrži srodni kadar u trening skupu**. Drugi nalaz je suptilniji i važniji. **Makro-F1 se naduvava dvostruko više od tačnosti**, jer curenje najviše pogoduje *retkim* klasama – klasa sa sedam sekvenci nema raznovrsnosti preko koje bi generalizovala, pa njeni izdvojeni kadrovi postaju gotovo pretraga u tabeli. Metrika izabrana *zbog* neuravnoteženosti je ona koju curenje najviše kviri.

Praktična zamka vredna beleženja. Prefiks TTTTT u imenu datoteke **nije** globalni identifikator sekvence – numeracija se restartuje unutar svakog direktorijuma klase. 39.209 slika daje samo 75 različitih sirovih prefiksa, ali **1.307** različitih parova (klasa, sekvenca). Ključ mora biti taj par; upotreba sirovog prefiksa tiho sažima 1.307 sekvenci u 75 grupa.




Figure 2: Trideset kadrova jedne sekvence i raspored koji im dodeljuje svako od dva pravila podele. Niz je uređen po rednom broju kadra, pa se čita kao približavanje vozila — kadrovi jesu *skoro* duplikati, a ne identični, što je razlog zašto ih nijedna provera duplikata ne bi uhvatila. Medijalna korelacija piksela između dva kadra iste sekvence je **0,61**, naspram **0,17** između dve slike iz *različitih* sekvenci iste klase.

4.2 Pretprocesiranje

Svaki isečak se skalira na 48×48 piksela. Definisane su tri konfiguracije: **raw_gray** (sivo), **clahe_gray** (sivo + CLAHE) i **clahe_hsv** (HSV + CLAHE nad V kanalom).

Pretprocesiranje je fiksirano na raw_gray za celo poređenje. Ranija verzija protokola je dozvoljavala da svaka metoda bira sopstvenu konfiguraciju, ali to čini svaku razliku između metoda mešavinom reprezentacije i pretprocesiranja – što je upravo konfuzija koju postavka isključuje. **raw_gray** je neutralan, neobrađen ulaz, i konfiguracija koju je HOG i sam izabrao.

Jedan detalj implementacije je merljivo bitan. **Interpolacija pri skaliranju bira se po slici** (39,2% isečaka se smanjuje, 60,8% uvećava). Fiksni izbor ubacuje artefakt od oko četiri nivoa sivog, koreliran sa veličinom znaka – što je uporedivo sa šumom $\sigma = 5$ – direktno u sliku 4 (tačnost po veličini znaka).

4.3 Kontrolisane degradacije

Tri degradacije, svaka po pet nivoa. Izabrane su tako da napadaju *različita* svojstva: šum **dodaje** visokofrekventnu energiju, zamućenje je **uklanja** (suprotne operacije nad istom osom), a gama korekcija je **ortogonalna** – geometrija ostaje netaknuta, menja se samo intenzitet.

degradacija	nivoi	identitet
Gausov šum	$\sigma \in \{0, 5, 10, 20, 40\}$	$\sigma = 0$
Zamućenje usled kretanja	$k \in \{0, 3, 5, 9, 15\}$ px, nasumičan ugao	$k = 0$
Gama korekcija	$\gamma \in \{0,4; 0,7; 1,0; 1,5; 2,5\}$	$\gamma = 1,0$

Identitet gama korekcije je **u sredini opsega**, a ne na kraju. Pretpostavka da je prvi nivo referentan tiho bi normalizovala sve gama krive u odnosu na $\gamma = 0,4$; registar degradacija zato eksplicitno deklarise identitet po degradaciji.

Degradacije se primenjuju na pretprocesiran ulaz modela 48×48 , a ne na izvornu rezoluciju. Time je ono što se ubacuje po konstrukciji *ostatak koji pretprocesiranje nije uklonilo* – veličina koju poređenje zaista meri, i za koju nije potrebna nijedna tvrdnja o kamerama. Takođe održava značenje nivoa jednoznačnim, jer bi degradacija na izvoru učinila da $\sigma = 20$ obuhvata izmereni opseg efektivnih jačina od $2,4 \times$ u zavisnosti od veličine znaka, čime bi se krive robusnosti pomešale sa analizom tačnosti po veličini znaka.

Svaka slika se degradira *seed*-om izvedenim iz njene *putanje*, a ne iz pozicije u nizu, pa svih pet metoda vidi bit-identične degradirane piksele bez obzira na redosled izvršavanja.




Figure 3: Svaka degradacija na svakom nivou, nad istim uzorkom. Prikazan je stvarni ulaz modela 48×48 ; nivo identiteta je uokviren, a kod gama korekcije se nalazi u sredini reda.

4.4 Izbor hiperparametara i protokol evaluacije

Sve odluke o hiperparametrima donose se **isključivo nad validacionim skupom**, po makro-F1 meri. **Test skup je dodirnut tačno jednom**, pri finalnoj mreži evaluacije.

Parametar regularizacije C linearnog SVM-a **podešava se po metodi**. „Fiksni klasifikator” znači isti estimator i isti protokol izbora, a *ne* istu vrednost pomoćnog parametra. PCA je jedina reprezentacija koja nije interno normalizovana (raspon standardnih devijacija obeležja je $87\times$), pa bi zamrznuta vrednost C svakoj metodi dala dugme kalibrisano za tuđu skalu obeležja.

Nasuprot tome, `class_weight` je **fiksiran na „balanced” za sve metode**. Razlika je suštinska. C je jačina regularizacije, pa dve metode sa različitim C i dalje minimizuju istu funkciju gubitka, dok `class_weight` menja *šta je* funkcija gubitka. Vrednost „balanced” je izabrana jer makro-F1 sve klase tretira jednako, pa joj odgovara i klasno uravnotežen cilj treniranja.

Nijedna tvrdnja o efektu klasnog ponderisanja se ne izvodi iz ovoga — razlika je mala i nestabilna (0,55 pp u korist „balanced” pri jednoj konfiguraciji, a gubitak pri drugoj), i za PCA je „balanced” čak *lošiji* izbor. Reč je o odluci radi uporedivosti, ne o rezultatu.

Sve metode treniraju se **samo nad trening podskupom** (31.379 slika), nikada nad trening+validacija, jer konvolucionoj mreži validacija treba za *early stopping*; davanje ostalim metodama 25% više podataka pomešalo bi poređenje.

5. Reprezentacije i implementacione odluke

5.1 PCA – holistička reprezentacija

Konstrukcija Eigenfaces [1] primenjena na saobraćajne znake. Svaka slika 48×48 je tačka u $\mathbb{R}^{2304}$, a reprezentacija su koordinate u bazi vodećih k sopstvenih vektora. Izabrano $k = 256$ nad validacijom.

Whitening se ne koristi, iz razloga vernosti konstrukciji. „PCA reprezentacija” u Eigenfaces smislu je ortogonalna projekcija, a whitening je komponuje sa dijagonalnim skaliranjem, pa koordinate koje klasifikator vidi više ne bi bile projekcije koje slika sa sopstvenim znakovima prikazuje.

Dva merenja koja objašnjavaju kasnije ponašanje pod gama korekcijom. **Prva glavna komponenta je osvetljenost** — nosi 52,3% varijanse i korelira +0,9975 sa srednjom intenzitetom slike — dakle preko polovine varijanse koju PCA modeluje jeste smetnja bez ikakve informacije o klasi. I drugo, **pri $k = 2$ se svaki znak, uključujući trouglaste, rekonstruiše ka okruglom disku ograničenja brzine**. Vodeće komponente kodiraju modalni oblik skupa, što čini svojstvo „holistička, bez pojma o delu” vidljivim.




Figure 4: Prvih 16 sopstvenih vektora kao slike („sopstveni znakovi”), sa udelom varijanse. PC1 je osvetljenost (39,8% posle CLAHE), PC2 razlikuje okruglo od trouglastog (12,7%) – najgrublja klasna razlika. **Diskriminativni detalj, koja cifra i koji piktogram, živi ispod 1% po komponenti.** PCA troši kapacitet po redosledu varijanse, ne po korisnosti.

5.2 HOG – kruta mreža, raspored očuvan

Histogrami orijentacija gradijenata [2] preko `scikit-image` [10]. Izabrano nad validacijom: ćelije 6×6 px, 9 orijentacija, blok-normalizacija L2-Hys, 1764 dimenzije.

HOG ništa ne uči – njegova faza treniranja je samo *fit* SVM-a, a njegov „model” su isključivo koeficijenti SVM-a. To je fiksirano testom koji zahteva da deskriptori dobijeni nad dve disjunktne polovine skupa budu bit-identični.

Izmereno: **linearna promena kontrasta se poništava tačno** (srednja promena deskriptora 0,0000), dok se **gama korekcija poništava samo delimično** (0,0339). Ta razlika je mehanizam koji objašnjava ponašanje HOG-a pod gama korekcijom u odeljku 6.

Veličina ćelije dominira nad brojem orijentacija. Prelazak sa 8 px na 6 px вреди oko 3,5 pp, dok prelazak sa 9 na 12 orijentacija ne вреди ništa. Na ulazu 48×48 ograničenje je prostorna, a ne ugaona rezolucija.

5.3 BoVW – reprezentacija bez prostornog rasporeda

Gusti SIFT [3] na fiksnoj mreži, rečnik vizuelnih reči dobijen k-sredinama, pa histogram učestanosti reči [4]. **Detektor se ne koristi.** Na isečcima ove veličine detektor vraća promenljiv broj *keypoint*-a po slici, pa histogrami ne bi bili uporedivi, a u graničnom slučaju vraća nula tačaka i tiho proizvodi multi histogram.

Parametri koje je plan predvideo bili su ubedljivo najveća greška u projektu. Vrednosti `step=6`, `keypoint_size=12` daju makro-F1 0,3455; podešavanje geometrije nad validacijom dovelo je metodu na 0,8808 – **poboljšanje od 53,5 pp**, veće od bilo koje razlike između metoda izmerene u ovom radu.

Presudna veličina je **razmera deskriptora, a ne gustina uzorkovanja**. Pošto `step` fiksira broj *keypoint*-a nezavisno od `keypoint_size`, ta dva efekta se razdvajaju — pri fiksni 256 tačaka, promena razmere sa 6 na 4 px vredi +12,3 pp, dok pri fiksnoj razmeri 2,25× veća gustina vredi +2,2 pp – oko 5,3× manje. Deskriptor od 12 px na isečku od 48 px opisuje četvrtinu objekta i nije lokalni ni u kom korisnom smislu.

5.4 Konvoluciona mreža – naučena reprezentacija

Tri bloka (konvolucija, batch normalizacija, ReLU) ×2, širine 32 → 64 → 128, pa potpuno povezana glava. Ukupno **882.379 parametara**, ispod zadatog budžeta od milion.

Globalno usrednjavanje je odbačeno iz strukturnog, a ne iz razloga performansi. Ono bi reprezentaciju učinilo *bez prostornog rasporeda* – što je upravo definišuće svojstvo BoVW metode – pa bi dve od četiri reprezentacije zauzele istu tačku na osi rasporeda i ta osa bi prestala da bude merljiva. Zabeleženo kao ograničenje. Glava mreže je manja nego što bi slobodan izbor dao, radi uporedivosti.




Figure 5: Dva izlaza jedne mreže — softmax glava daje `cnn_e2e`, a preposlednji sloj se grana u zajednički linearni SVM i daje `cnn_feat_svm`. U celom projektu postoji tačno jedno treniranje mreže – `cnn_feat_svm` ne trenira ništa novo.

Uz to ide obavezna ograda. Obeležja su optimizovana za *softmax* glavu, pa ako `cnn_feat_svm` zaostaje za `cnn_e2e`, deo te razlike je neslaganje ciljeva, a ne svojstvo reprezentacije. PCA, HOG i BoVW nikada nisu optimizovani ni za jedan klasifikator, pa je ta asimetrija svojstvena samo mreži.

6. Rezultati

6.1 Tabela 1 – poređenje na čistom test skupu

Metoda	Tačnost	makro-F1	Dim.	Trening (s)	1 slika (ms)	Model (MB)
CNN <i>end-to-end</i>	0,9785	0,9684	128	2595,9	1,400	3,38
CNN obeležja + SVM	0,9804	0,9651	128	1,1 [†]	2,037	0,04 [†]
HOG + SVM	0,9238	0,9062	1764	81,5	0,983	0,58
BoVW + SVM	0,9141	0,8596	1000	89,9	2,792	1,59
PCA + SVM	0,7932	0,7312	256	33,3	0,327	2,35

Tri ograde idu uz ovu tabelu i bez njih je pogrešno čitati.

[†] Kolone za `cnn_feat_svm` nisu uporedive sa ostalima. Vrednost 1,1 s je vreme *fit*-ovanja samo SVM glave, što bi ovu metodu prikazalo kao najjeftiniju za treniranje u celom radu; ona ne može postojati bez mreže od 2596 s koju čita, pa je pošteno vreme ≈ 2597 s. Isto važi za veličinu modela — 0,04 MB je samo glava, a poštena vrednost je 3,42 MB.

Vremena su indikativna, a ne poređenje. Svaka metoda je merena u sopstvenom izvršavanju, drugog dana, pri različitom opterećenju sistema – jednogminutni *load average* kretao se od 1,27 do 13,12 na mašini sa 16 niti. Uz to, promena profila napajanja procesora sama po sebi menja vremena za oko 20%, a na `amd-pstate` platformi ta promena nije vidljiva u `scaling_governor` vrednosti.

Veličina modela nije uporediva ni između ostalih redova. 96% od 2,35 MB kod PCA je naučena *baza*, dok HOG nema nijednu *fit*-ovanu fazu, pa je njegovih 0,58 MB u celosti SVM. Tabela inače čitaocu sugerise da je „PCA četiri puta veći od HOG-a”, dok je stvarna razlika naučen rečnik naspram nijednog.

Konačno, odnos *batch* i pojedinačne inferencije je specifičan za metodu — PCA 52 $\times$, BoVW 2,0 $\times$, HOG 1,3 $\times$, CNN 1,4 $\times$. Kamera daje jedan kadar u jednom trenutku, pa je pojedinačna kolona ona koju sme koristiti bilo kakva tvrdnja o kašnjenju – i u njoj se ogromna prednost PCA metode svodi sa 200 $\times$ na 8,5 $\times$.

6.2 Krive robusnosti – glavni rezultat




Figure 6: Makro-F1 zadržan u odnosu na sopstvenu čistu vrednost svake metode. Normalizacija je namerna, jer su apsolutne krive dominirane time *odakle* svaka metoda kreće, a pitanje ovde nije ko je najbolji – to govori Tabela 1 – već **koliko brzo svaka opada**.

zadržano (%)	PCA	HOG	BoVW	CNN obel.	CNN e2e
šum $\sigma = 10$	97,4	61,9	93,5	89,2	89,2
šum $\sigma = 20$	89,8	37,0	82,8	71,8	71,4
šum $\sigma = 40$	76,7	14,8	65,6	44,3	43,8
zamućenje $k = 9$	80,0	53,7	61,4	71,6	73,8
zamućenje $k = 15$	45,1	23,9	20,7	36,8	39,6
gama 0,4	79,9	99,9	98,9	99,0	98,4
gama 2,5	70,1	89,2	95,3	86,2	86,1

Redosled uspešnosti se invertuje pod šumom. Na čistom ulazu poredak je CNN > CNN-obeležja > HOG > BoVW > PCA; pri $\sigma = 40$ poredak je BoVW > PCA > CNN-obeležja > CNN > HOG. Spearman-ova korelacija sa čistim poretkom je **-0,60**.

Dve tvrdnje se moraju držati odvojeno. **Po zadržanoj vrednosti** – što je mera robusnosti i ono što slika prikazuje – PCA je ubedljivo najbolja pri $\sigma = 40$ – 76,7% naspram 65,6% za BoVW, $\approx 44\%$ za mreže i 14,8% za HOG. **Po apsolutnom makro-F1** PCA i BoVW su izjednačeni (0,5606 i 0,5639; razlika od 0,33 pp je unutar razlučivosti ovog rada), ali su *obe* daleko ispred obe mreže ($\approx 0,425$) i HOG-a (0,1341).

Tvrdnja koja preživljava i koja je bitna. **Pod jakim šumom dve metode koje su na čistim podacima poslednja i četvrta postaju dve najbolje, i obe nadmašuju konvolucionu mrežu na istim pikselima.** To je slučaj u kome je uobičajen odgovor – „koristi mrežu” – merljivo pogrešan za navedeni uslov.

Inverzija je specifična za degradaciju, a ne opšta. Pod zamućenjem i gama korekcijom Spearman-ova korelacija sa čistim poretkom je +0,70 i +0,90, dakle poredak uglavnom prati čistu uspešnost. Premisa se potvrđuje, ali je nosi jedna od tri degradacije, i izveštaj to mora reći umesto da sugerise opštu nestabilnost poretka.

6.2.1 Ista slika po tačnosti – i jedna razlika koju treba imenovati

Odeljak 6.3 predloga navodi *tačnost* kao meru za krive robusnosti, dok se gore vodi makro-F1 – metrika po kojoj je svaka metoda i birana. **Obe verzije su izrađene** (*robustness_curves.png* i *robustness_curves_accuracy.png*) i **upoređene su, a ne pretpostavljeno da se slažu.**

Svaka ocena „najbolji” i „najlošiji” je identična po obe metrike, na sve tri degradacije: PCA najbolja i HOG najlošiji pod šumom, PCA najbolja i BoVW najlošija pod zamućenjem, BoVW najbolja i PCA najlošija pod gama korekcijom. Nijedan zaključak u ovom izveštaju ne zavisi od izbora metrike.

Jedan broj se ipak bitno razlikuje, i on ograničava prethodni pasus:

Spearman sa čistim poretkom	makro-F1	tačnost
šum $\sigma = 40$	-0,60	-0,70
zamućenje $k = 15$	+0,70	+0,60
gama 2,5	+0,90	+0,10

Pod gama korekcijom je poredak *po tačnosti* praktično **nepovezan** sa čistom uspešnošću (+0,10), dok ga poredak po makro-F1 blisko prati (+0,90). To i dalje nije inverzija – korelacija je blizu nule,

a ne negativna – ali tvrdnja „zamućenje i gama prate čist poredak” **važi za makro-F1 i mora se tako i napisati.**

Uzrok se vidi u apsolutnim vrednostima. Po tačnosti pri $\gamma = 2,5$ poredak je BoVW > HOG > CNN-obeležja > CNN > PCA, to jest dve ručno projektovane metode sa najjačom internom normalizacijom penju se iznad obe mreže. Po makro-F1 mreže ostaju na vrhu, jer ih gama korekcija najviše košta na *retkim* klasama – koje makro-F1 ponderiše jednako, a tačnost ne.




Figure 7: Krive robusnosti po tačnosti – mera koju odeljak 6.3 predloga imenuje. Oblik je isti kao na slici po makro-F1, a razlika je u gama panelu, gde se BoVW i HOG penju iznad obe mreže.

6.3 Greške na čistom ulazu – metode ne greše na istim mestima




Figure 8: Matrice konfuzije, najbolja i najlošija metoda. Normalizovano po redovima, jer se test klase razlikuju 12,5x po učestanosti, pa bi sirovi brojevi velike klase prikazali lošijim samo zato što su velike.

Preklapanje deset najčešćih parova zamene, po metodama:

	PCA	HOG	BoVW	CNN obel.	CNN e2e
PCA	10	4	2	0	1
HOG	4	10	4	0	1
BoVW	2	4	10	1	2
CNN obel.	0	0	1	10	6
CNN e2e	1	1	2	6	10

Nijedna klasa nije među pet najlošijih kod svih metoda, i nijedan par nije među deset najčešćih kod svih metoda. Umesto toga postoje dve grupe — tri ručno projektovane metode dele greške međusobno, dok dva reda konvolucione mreže dele šest parova međusobno i **nula do dva sa bilo čim ručno projektovanim** – `cnn_feat_svm` deli *nijedan* od svojih deset parova sa PCA i *nijedan* sa HOG-om.

Dakle mreža nije „isto to, samo bolje” – ona **greši drugačije**. To je jača formulacija interakcije između reprezentacije i težine klase nego što je daje mreža robusnosti, jer važi na *čistim* podacima, gde svih pet metoda radi dobro.

6.4 Tačnost po veličini znaka

Accuracy by sign size — the same clean-test predictions, grouped by ROI height
 Free: figure 9.2's predictions, partitioned differently. **Y axis starts at 0.70** — all five methods lie in [0.74, 1.00].
 The smallest bucket is not a tail: 47.6 % of training images are under 32 px (note 02), so this is the MODAL case, and train/test size distributions agree to within 0.1 pp.
 At <32 px: best CNN feat + SVM 0.975, worst PCA 0.740.




Figure 9: Iste predikcije nad čistim test skupom, grupisane po visini graničnog okvira. Najmanji opseg nije rep raspodele, jer je 47,6% trening slika je ispod 32 px, pa je to *modalni* slučaj, a raspodele veličina u trening i test skupu se poklapaju na 0,1 pp.

Metoda	[0,32)	[32,48)	[48,72)	[72,∞)	pad
PCA	0,740	0,854	0,853	0,775	+3,5 pp
HOG	0,885	0,957	0,959	0,966	+8,1 pp
BoVW	0,892	0,946	0,930	0,902	+1,0 pp
CNN obel.	0,975	0,993	0,984	0,960	−1,5 pp
CNN e2e	0,969	0,989	0,986	0,984	+1,5 pp

PCA je **nemonotona**, sa maksimumom u srednjim opsezima. Veliki znaci se pri skaliranju na 48×48 smanjuju, a mali uvećavaju, i PCA je jedina metoda bez interne normalizacije koja bi razliku u efektivnoj ošttrini apsorbovala. Navedeno kao hipoteza, ne kao nalaz.

7. Diskusija

Ovaj odeljak je poređenje koje odeljak 6.4 predloga navodi kao jezgro diskusije. Očekivanja su zaključana **13. 09. 2026. u 14.24**, a prvi rezultat bilo kog modela upisan je istog dana **u 20.36** – redosled je proverljiv iz istorije verzija repozitorijuma, a ne samo tvrđen. Obrazloženja su izvedena iz strukturnih osobina iz tabele u odeljku 1.2, kako predlog i nalaže.

7.1 Očekivanja naspram ishoda

Očekivanja su zapisana **13. 09. 2026, pre nego što je ijedan model postojao** i nisu naknadno menjana. Od deset iskaza o robusnosti, **osam se obistinilo**.

Očekivanje (13. 09. 2026)	Ishod	
Šum: PCA najrobusnija	76,7%, prva	da
Šum: HOG najmanje robusna	14,8%, poslednja	da
Šum: BoVW između PCA i HOG	65,6%, druga	da
Zamućenje: PCA najrobusnija	45,1%, prva	da
Zamućenje: BoVW najmanje robusna	20,7%, poslednja	da
Zamućenje: HOG ispred BoVW (revidirano)	23,9% vs 20,7%	da
Gama: PCA najmanje robusna	70,1%, poslednja	da
Gama: HOG najrobusnija	BoVW 95,3% > HOG 89,2%	ne
Mali znaci: CNN najrobusnija	0,975 ispod 32 px	da
Mali znaci: BoVW najmanje robusna	BoVW najstabilnija; PCA najlošija	ne

Glavno očekivanje je potvrđeno u oba smera — PCA najbolja pod šumom i najlošija pod gama korekcijom, HOG najlošiji pod šumom. Osmi red nije pao zato što je HOG bio loš – on je i dalje drugi po gama robusnosti – već zato što ga je *treća* metoda nadmašila.

7.2 Prvi promašaj: tip normalizacije, a ne njeno postojanje

Očekivanje je glasilo da SIFT-ova normalizacija deskriptora daje BoVW metodi „sličnu (nešto slabiju)” zaštitu od HOG-ove. Izmereno, ta zaštita je **najjača u celom radu**.

Razlog je što su dve normalizacije pogrešno tretirane kao ista stvar različite jačine:

- **HOG-ov L2-Hys** normalizuje nad *blokom* od 2×2 ćelije – oblast od oko 12×12 px – i **linearan** je.
- **SIFT** normalizuje po *pojedinačnom deskriptoru* od 128 dimenzija, i uz to **clip-uje svaku komponentu na 0,2 pa ponovo normalizuje** [3]. Taj *clipping* je **nelinearnost**, i ono potiskuje upravo one velike gradijentne komponente koje gama kriva uvećava.

Linearni normalizator poništava linearnu promenu kontrasta tačno (0,0000 izmereno kod HOG-a), ali gama korekciju samo delimično (0,0339); *clipping* se gracioznije ponaša u oba slučaja.

Isto svojstvo objašnjava i drugi neočekivan nalaz. Zamućenje *ne* urušava rečnik vizuelnih reči, suprotno očekivanju. Broj različitih reči po slici pada samo sa 231,4 na 188,9 (–18%) između $k = 0$

i $k = 15$, a sličnost histograma različitih klasa ostaje ravna ($0,232 \rightarrow 0,244$). Zamućenje smanjuje *intenzitet* gradijenata, ali *pravac* deskriptora i dalje varira, a k -sredine dodeljuju po pravcu. **Jedan detalj deskriptora, dva nepredviđena ishoda.**

To ujedno objašnjava zašto je red o zamućenju ipak tačan, ali iz *drugog* razloga nego što je navedeno. BoVW je najlošija pod zamućenjem ne zato što joj se deskriptori urušavaju, već zato što nema prostorni raspored na koji bi se oslonila kada zamućenje spoji ivice.

7.3 Drugi promašaj: podešavanje je zamenilo metodu o kojoj je očekivanje gov- orilo

Navedeni mehanizam za male znake – „gusti SIFT ima premalo lokalne podrške” – bio je **ispravan za metodu koju je plan specificirao**, sa *keypoint*-ima od 12 px. Podešavanje je razmeru promenilo na **2 px**, a deskriptor od 2 px gotovo da i ne traži lokalnu podršku.

Dakle promena parametra od +53,5 pp nije samo popravila BoVW, već je **promenila na koje je degradacije metoda osetljiva** – dok je zamućenje ostavila netaknutim, jer tamo nedostaje *raspored*, a njega podešavanje ne isporučuje. Upštenije — **navedena slabost metode je tvrdnja o konfiguraciji, a ne o metodi.**

7.4 Koliko vredi odbacivanje prostornog rasporeda

Pošto *keypoint*-i leže na pravilnoj mreži, pripadnost prostornoj ćeliji poznata je već iz indeksa – informacija o položaju je bila *dostupna* sve vreme i BoVW je jednostavno odbacuje. To dopušta kontrolisan eksperiment — isti deskriptori, isti rečnik, isti klasifikator, a jedina razlika je da li se položaj beleži.

nivoi piramide	ćelija	dimenzija	makro-F1
0 – obična BoVW	1	500	0,8143
1 – 2×2	5	2.500	0,8973
2 – 4×4	21	10.500	0,9184

Prostorni raspored vredi +10,4 pp makro-F1, a nivo 2 pada na 0,1 pp od HOG-a (0,9175). Dakle razlika između BoVW i HOG-a *jeste* informacija o rasporedu, dok preostalih pet razlika između te dve metode zajedno ne doprinose gotovo ništa.

What 'orderless' actually means — the same descriptors, re-pooled after shuffling their positions
 Plain BoVW: $\max |\Delta| = 0.0e+00 \rightarrow$ the two histograms are the SAME VECTOR. Layout was never encoded, so destroying it costs nothing.
 BoVW + SPM: $\max |\Delta| = 0.0833 \rightarrow$ genuinely different, because the pyramid records WHERE each word occurred.
 That asymmetry IS the layout axis this study measures: BoVW discards position, HOG and the pyramid keep it.
 The original is reported as a diagnostic, not as a method — it is what it is. BoVW is a method that puts a number on the cost of orderless (L=20.4 pp).




Figure 10: Šta „bez prostornog rasporeda” zaista znači. Isti deskriptori, ponovo sažeti nakon nasumične permutacije njihovih položaja. **Obična BoVW: maksimalna razlika 0,0 – to je isti vektor, *bit-for-bit*.** Sa piramidom: 0,0833. Karta kodnih reči levo pokazuje da je struktura znaka zaista uništena, a histogram to *ne primećuje*.

Prostorna piramida se izveštava kao dijagnostika, a ne kao šesta metoda. Razlog je strukturni. BoVW je jedina metoda na strani „raspored odbačen” u tabeli iz odeljka 1.2, pa bi zamena ostavila tu osu bez ijedne metode – i HOG i piramida su krute mreže lokalnih histograma. Postojao je i praktičan razlog — pri izabranom rečniku od 1000 reči, nivo 2 ima 21.000 dimenzija i zahteva oko 6 GB radne memorije pri treniranju, što prevazilazi mogućnosti korišćene mašine.

7.5 Pretprocesiranje: presudna je interna normalizacija

Metoda	raw_gray	clahe_gray	clahe_hsv	interna normalizacija
PCA	0,7713	0,7977	0,7674	nema
HOG	0,9175	0,9138	0,8205	blok L2-Hys
BoVW	0,8808	0,8791	—	SIFT po deskriptoru + <i>clipping</i>
CNN e2e	0,9856	0,9872	0,9642	batch normalizacija

Nalaz je redosled poslednje kolone. Koliko pretprocesiranje utiče nije svojstvo toga da li je metoda „zasnovana na gradijentima” – što je očekivanje pretpostavljalo – već **da li reprezentacija interno normalizuje**. PCA, koja ne normalizuje, jedina ima korist od CLAHE, i to najveću (+2,64 pp). HOG, BoVW i mreža sve normalizuju interno i praktično su ravnodušne (–0,37 do +0,16 pp).

To ujedno opravdava fiksiranje pretprocesiranja, jer je **najveći efekat pretprocesiranja (2,64 pp) manji je od najmanje razlike između metoda na čistom test skupu (12,8 pp)**, pa fiksiranje ne može promeniti poredak.

Konfiguracija `clahe_hsv` gubi kod svake metode, ali to se ne sme čitati kao „boja nije informativna”. Reč je o **defektnom kodiranju boje**. U OpenCV HSV prostoru nijansa se obmotava na 0/179, a crvena – najčešća boja znakova – leži tačno na toj granici. Znak *Stop* ima 56,5% zasićenih piksela na nijansi ispod 10 i 4,4% iznad 169; 3,98% **gradijenata nijanse između susednih piksela prelazi 90**, a srednji gradijenti nijanse dostižu nivo gradijenata intenziteta, pa pobeđuju pri svakom izboru kanala po maksimalnom intenzitetu gradijenta.

Cena raste sa time koliko metoda diferencira — **HOG** –9,70 **pp** (bira gradijent najveće magnitude *preko kanala*, pa aktivno uzima pokvareni), mreža –2,14 pp **uz maksimum u epohi 5 umesto 18** (uči rani lažni signal koji ne generalizuje), PCA –0,39 pp (nikada ne diferencira). Ispravka je poznata (nijansa kao par $\cos/\sin$, ili CIELab prostor) i namerno nije primenjena, jer su sva podešavanja izvršena nad postojećom konfiguracijom.

8. Ograničenja

8.1 Statistička

Jedan *seed*, bez ponavljanja. Razlike od nekoliko desetih delova procentnog poena nisu interpretabilne, pa su tvrdnje gde god je moguće iskazane *ordinalno*. Projekat sadrži konkretan primer te granice. BoVW je imao veću validacionu tačnost od HOG-a (0,9330 naspram 0,9298), a na test skupu HOG vodi (0,9238 naspram 0,9141) – prednost od 0,3 pp nije preživela. Njihov poredak po makro-F1, gde je razlika 4,7 pp, stabilan je nad obema podelama.

8.2 Metodološka

Jedna konfiguracija pretprocesiranja u finalnoj mreži (*raw_gray*); stabilnost poretka kroz pretprocesiranje se *argumentuje* iz podešavanja po metodama, a ne meri nad test mrežom.

Dve metode su izveštane kao donje granice. Rečnik BoVW metode je ograničen na 1000 reči odlukom, a ne merenjem – prelazak sa 500 na 1000 i dalje je vredeo +3,7 pp pri izabranoj razmeri, pa veći rečnik verovatno donosi još oko 2 pp. **Stopa učenja konvolucione mreže nikada nije podešavana** — sva tri treniranja koristila su podrazumevanu vrednost 10^{-3} , pa je mreža jedina metoda čiji glavni optimizacioni hiperparametar nije biran nad validacijom. Smer te pristrasnosti je poznat – podešavanje bi moglo samo pomoći – pa je metoda koja već pobeđuje ujedno i ona koja je najmanje podešena.

Treniranje mreže je zaustavljeno pravilom ranog zaustavljanja, a ne potvrđenom konvergencijom. Zaustavljeno je u epohi 24, nakon što je poslednje poboljšanje zabeleženo u epohi 18 – to jest, isteklo je *patience* od šest epoha. Izveštaj koristi formulaciju „zaustavljeno”, nikada „konvergiralo”.




Figure 11: Levo: osenčen pojas je *patience* prozor. Vraćanje *poslednje* epohe umesto najbolje koštalo bi 0,63 pp makro-F1. Desno: gubitak nad trening skupom pada oko 1000× dok je validacioni makro-F1 ravan posle epohe 18 – posle te tačke mreža pamti, a ne generalizuje.

8.3 Perturbacija graničnog okvira nije izvodljiva nad GTSRB skupom

Prvobitno je planirana i četvrta degradacija – perturbacija graničnog okvira, koja bi najdirektnije povezala ovaj modul sa detektorom. **Analiza skupa je pokazala da ona nad GTSRB skupom nije izvodljiva na pošten način, i to merenje je samo po sebi rezultat.**

GTSRB slike su *već isečene* oko znaka, sa medijanom margine od svega 16,7%; sve izvan te margine

odbačeno je pri formiranju skupa i ne postoji ni u jednoj datoteci. Medijalna rezerva za širenje okvira je $1,30\times$, pa je **proširenje od +40% nemoguće za 72% slika** (28.166 isečaka bi izašlo izvan granica datoteke). Jedini način da se takav pomeraj ipak proizvede jeste veštačko dopunjavanje ivica, čime bi se merio postupak dopunjavanja, a ne reprezentacija.

Ispravan instrument je skup punih saobraćajnih scena (GTSDb [9]), što je ostavljeno kao proširenje. Vredi zabeležiti da rezultat iz odeljka 7.4 daje direktnu i proverljivu hipotezu za to proširenje — metoda bez prostornog rasporeda trebalo bi da bude *najotpornija* na pomeraj okvira, iz istog razloga iz kog je najlošija pod zamućenjem.

9. Zaključak

Pet konfiguracija klasifikacije upoređeno je nad jedinstvenim protokolom — ista podela po sekven-cama, isto preprocesiranje, isti klasifikator, ista metodologija evaluacije. Nad test skupom izvršeno je 80 evaluacija bez ijednog nedostajućeg polja.

Pet nalaza:

1. **Redosled uspešnosti se invertuje pod šumom, i tamo je uobičajen odgovor pogrešan.** PCA je poslednja na čistom test skupu (0,7312) i zadržava 76,7% pri $\sigma = 40$, gde HOG zadržava 14,8% – razlika od $5,2\times$, Spearman $-0,60$ u odnosu na čist poredak. I PCA i BoVW nadmašuju obe mreže po apsolutnom makro-F1 na tom nivou. **Ali inverzija je vezana za vrstu degradacije.** Zamućenje i gama korekcija koreliraju *pozitivno* sa čistom uspešnošću (+0,70 i +0,90).
2. **Naučena obeležja nisu automatski i robusna obeležja.** Mreže vode na čistom ulazu za oko 6 pp, a pod šumom su u sredini tabele i gube od linearne projekcije u 256 dimenzija. Trenirane su isključivo na čistim podacima i ništa u njihovom cilju nije nagrađivalo otpornost na šum – što i jeste poenta. Kapacitet i čista tačnost ne impliciraju robusnost, pa praktičar koji bira za poznat uslov ne može robusnost pročitati sa rang-liste.
3. **Otpornost na promene intenziteta kupuje interna normalizacija – i njen *típ* je bi-tan.** Metode koje normalizuju interno gotovo su ravnodušne na CLAHE i preživljavaju gama korekciju; PCA, koja ne normalizuje, najlošija je u oba slučaja. Uz to, **nelinearna normalizacija nadmašuje linearnu** — SIFT-ov *clipping* i ponovna normalizacija po deskriptoru zadržava 95,3% pri $\gamma = 2,5$, naspram 89,2% za HOG-ov blok-L2.
4. **Odbacivanje prostornog rasporeda je skupo, i ta cena je merljiva izolovano.** Dodavanje prostornih ćelija BoVW metodi – uz iste deskriptore, isti rečnik i isti klasifikator, gde je jedina promena da li se položaj beleži – vredi +10,4 pp makro-F1 i dovodi metodu na 0,1 pp od HOG-a. Test permutacijom to čini egzaktnim. Mešanje položaja *keypoint*-a ostavlja običan histogram **bit-identičnim**.
5. **Parametri su dominirali nad metodom.** Ponovno podešavanje geometrije deskriptora kod BoVW metode pomerilo ju je za +53,5 **pp** (0,3455 $\rightarrow$ 0,8808), više nego bilo koja razlika između metoda u ovom radu, i **promenilo na koje je degradacije osetljiva**. Navedena slabost metode je tvrdnja o konfiguraciji, a ne o metodi – i sopstveno unapred zapisano očekivanje ovog rada o malim znacima poništeno je sopstvenim podešavanjem.

Praktična preporuka koja sledi iz postavke iz odeljka 1. Reprezentaciju treba birati prema degradaciji koja u datoj primeni dominira, a ne prema tačnosti na čistim podacima. Za scenario u kome dominira šum pri slabom osvetljenju, PCA ili BoVW su merljivo bolji izbor od konvolucione mreže na istom ulazu – uprkos tome što su na čistim podacima poslednji i četvrti.

10. Literatura

- [1] M. Turk and A. Pentland. Face recognition using eigenfaces. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 586–591, 1991.
- [2] N. Dalal and B. Triggs. Histograms of oriented gradients for human detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893, 2005.
- [3] D. G. Lowe. Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60(2):91–110, 2004.

- [4] G. Csurka, C. Dance, L. Fan, J. Willamowski, and C. Bray. Visual categorization with bags of keypoints. In *ECCV Workshop on Statistical Learning in Computer Vision*, pages 1–22, 2004.
- [5] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel. Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition. *Neural Networks*, 32:323–332, 2012. https://benchmark.ini.rub.de/gtsrb_dataset.html.
- [6] Y. Bengio, A. Courville, and P. Vincent. Representation learning: A review and new perspectives. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 35(8):1798–1828, 2013.
- [7] D. Cireşan, U. Meier, J. Masci, and J. Schmidhuber. Multi-column deep neural network for traffic sign classification. In *Neural Networks*, volume 32, pages 333–338, 2012.
- [8] A. Møgelmoose, M. M. Trivedi, and T. B. Moeslund. Vision-based traffic sign detection and analysis for intelligent driver assistance systems: Perspectives and survey. *IEEE Transactions on Intelligent Transportation Systems*, 13(4):1484–1497, 2012.
- [9] S. Houben, J. Stallkamp, J. Salmen, M. Schlipsing, and C. Igel. Detection of traffic signs in real-world images: The German Traffic Sign Detection Benchmark. In *International Joint Conference on Neural Networks (IJCNN)*, 2013. https://benchmark.ini.rub.de/gtsdb_news.html.
- [10] S. van der Walt, J. L. Schönberger, J. Nunez-Iglesias, F. Boulogne, J. D. Warner, N. Yager, E. Gouillart, and T. Yu. scikit-image: Image processing in Python. *PeerJ*, 2:e453, 2014. <https://scikit-image.org/>.